



جامعة هواري بومدين للعلوم والتكنولوجيا  
Université des Sciences et de Technologie Houari Boumediene

Faculté d'Informatique

---

# RAPPORT TECHNIQUE

## Deep Learning for Crop Classification Using Multi-Source Satellite Data

---

Membre de l'équipe 2 :

**Benaicha  
Miri  
Attari**

**Chahinez  
Wiam  
Lina**

Groupe : 3

Année universitaire : 2025/2026

## Contents

|                                                                  |    |
|------------------------------------------------------------------|----|
| 1. Introduction et contexte du projet .....                      | 3  |
| 2. Description des données et pipeline de prétraitement .....    | 4  |
| 2.1 Données Sentinel-2 (images satellitaires) .....              | 4  |
| 2.2 Cropland Data Layer (CDL) .....                              | 4  |
| 2.3 Pipeline d'acquisition GEE.....                              | 4  |
| 2.3.1. Étape échantillonnage.....                                | 4  |
| 2.3.2. Étape extraction des bandes spectrales .....              | 4  |
| 2.4 Prétraitement Python .....                                   | 5  |
| 2.4.1. Normalisation .....                                       | 5  |
| 2.4.2. Split train/val/test.....                                 | 5  |
| 3. Partie 1 : MCNet .....                                        | 6  |
| 3.1 Architecture MCTNet .....                                    | 6  |
| 3.2 Implémentation et entraînement.....                          | 6  |
| 3.3 Résultats .....                                              | 6  |
| 3.3.1 Résultats Arkansas.....                                    | 6  |
| 3.3.2 Résultats California .....                                 | 7  |
| 3.4 Analyse des Résultats.....                                   | 8  |
| 4. Partie 2 : Intégration des covariables environnementales..... | 9  |
| 4.1 Choix des covariables .....                                  | 9  |
| 4.1.1 Covariables climatiques.....                               | 9  |
| 4.1.2 Covariables pédologiques (Soil) .....                      | 10 |
| 4.1.3 Covariables topographiques.....                            | 11 |
| 4.2 Résultats Ablation.....                                      | 12 |
| 4.2.1 Résultats Arkansas.....                                    | 12 |
| 4.2.1 Résultats California.....                                  | 13 |
| 4.2.3 Discussion et analyse comparative .....                    | 14 |
| 5. Partie 3 : Conception et amélioration de modèles .....        | 16 |
| 5.1 objectifs .....                                              | 16 |
| 5.2 Enrichissement des données.....                              | 16 |
| 5.2.1 Motivation.....                                            | 16 |
| 5.2.2 Les indices de végétation .....                            | 16 |
| 5.2.3 Dimensions finales des datasets .....                      | 17 |
| 5.3 Architecture du modèle — Part3Net .....                      | 18 |
| 5.3.1 Module FeatureAttention.....                               | 18 |
| 5.3.2 Flux global du modèle.....                                 | 18 |
| 5.3.3 Hyperparamètres.....                                       | 19 |
| 5.4 Résultats .....                                              | 19 |
| 5.4.1 Résultats Arkansas.....                                    | 19 |
| 5.4.2 Résultats California .....                                 | 20 |
| 5.4.3 Discussions et analyse comparatives .....                  | 21 |
| 5.4.4 Conclusion.....                                            | 22 |
| 6. Conclusion générale .....                                     | 23 |

# 1. Introduction et contexte du projet

La surveillance des types de cultures agricoles à grande échelle constitue un enjeu fondamental pour la gestion agricole, l'évaluation de la sécurité alimentaire et le suivi environnemental. L'imagerie satellitaire offre un moyen puissant de cartographier les cultures à grande échelle, en particulier lorsqu'on utilise des observations en séries temporelles qui capturent le développement phénologique de la végétation tout au long de la saison de croissance.

Les avancées récentes en apprentissage profond ont considérablement amélioré la précision de la classification des cultures. En particulier, les architectures hybrides combinant des réseaux de neurones convolutifs (CNN) et des Transformers ont démontré des performances élevées dans la modélisation des dépendances temporelles dans les données satellitaires. Ce projet s'inscrit dans cette dynamique en reproduisant et étendant la méthodologie proposée par Wang et al. (2024).

Ce rapport décrit le travail réalisé en trois parties principales. La **Partie 1** vise à reproduire fidèlement le pipeline de préparation des données et l'architecture MCTNet (Multi-scale Convolutional Transformer Network) proposés dans le papier de référence<sup>1</sup>. La **Partie 2** étend le cadre en intégrant des covariables environnementales supplémentaires (climatiques, pédologiques et topographiques) pour évaluer leur impact sur la précision de classification à travers une étude d'ablation systématique. Enfin, la **Partie 3** consiste à concevoir et évaluer notre propre modèle, en nous inspirant du travail accompli et d'autres travaux de recherche.

Les deux régions d'étude sont situées aux États-Unis : l'Arkansas et la Californie.

---

<sup>1</sup> Wang et al. (2024). A lightweight CNN-Transformer network for pixel-based crop mapping using time-series Sentinel-2 imagery. Computers and Electronics in Agriculture.

## 2. Description des données et pipeline de prétraitement

### 2.1 Données Sentinel-2 (images satellitaires)

Sentinel-2 est un système d'imagerie multispectrale de l'Agence spatiale européenne (ESA) conçu pour l'observation haute résolution de la surface terrestre. Les données de réflectance de surface (niveau 2A, corrigées des effets atmosphériques) ont été collectées via Google Earth Engine pour l'année 2021. Parmi les 13 bandes disponibles, 10 ont été retenues pour leurs propriétés spectrales (3 bandes visibles, 4 bandes *red-edge*, 1 proche infrarouge et 2 infrarouges à ondes courtes), les bandes 1, 9 et 10 ayant été exclues en raison de leur résolution spatiale insuffisante (60 m).

### 2.2 Cropland Data Layer (CDL)

La *Cropland Data Layer* (CDL) de 2021 sert de référence pour la labellisation des types de cultures. Il s'agit d'une carte de l'occupation des terres agricoles au niveau du pixel (30 m), produite annuellement pour les États-Unis, et en complément, la carte *ESA WorldCover 2021*, issue des données Sentinel-1 et Sentinel-2, a été utilisée comme masque pour exclure les zones non agricoles, facilitant ainsi la sélection des données pertinentes. Afin de garantir la fiabilité des échantillons, nous avons appliqué un seuil de confiance de 95% sur les données CDL.

### 2.3 Pipeline d'acquisition GEE

L'acquisition des données repose sur un protocole en deux étapes implémentées dans le script `step0_gee_arkansas_v5.js` :

#### 2.3.1. Étape échantillonnage

La fonction `stratifiedSample()` de GEE est utilisée pour garantir exactement N (10 000) points par classe, répartis sur 2 zones géographiques par état.

#### 2.3.2. Étape extraction des bandes spectrales

Pour chacun des 36 intervalles de 10 jours, un composite médian est calculé. Le filtre SCL (*Scene Classification Layer*) est appliqué pour masquer les nuages, l'eau et les ombres. Les données manquantes sont remplacées par une valeur nulle (0), tandis qu'une variable binaire permet de conserver l'information du masque (1 si manquant, 0 si présent).

#### *Classes Arkansas (5 classes)*

| Label | Classe          | Code CDL | Points (total) |
|-------|-----------------|----------|----------------|
| 0     | Corn (Maïs)     | 1        | 1 520          |
| 1     | Cotton (Coton)  | 2        | 760            |
| 2     | Rice (Riz)      | 3        | 2 420          |
| 3     | Soybean (Soja)  | 5        | 4 680          |
| 4     | Others (Autres) | >5       | 620            |

#### *Classes California (6 classes)*

| Label | Classe            | Code CDL | Points (total) |
|-------|-------------------|----------|----------------|
| 0     | Grapes (Vignes)   | 27       | 2 060          |
| 1     | Rice (Riz)        | 3        | 2 040          |
| 2     | Alfalfa (Luzerne) | 36       | 980            |
| 3     | Almonds (Amandes) | 75       | 780            |

| Label | Classe                 | Code CDL | Points (total) |
|-------|------------------------|----------|----------------|
| 4     | Pistachios (Pistaches) | 204      | 640            |
| 5     | Others (Autres)        | divers   | 3 520          |

## 2.4 Prétraitement Python

Le script `cal_step_1_Merge.py` fusionne les 74 CSV GEE (2 CDL + 36×2 spectral) en un fichier NPZ unique. La matrice résultante  $X$  possède la forme de  $[N, T, C]$  où  $N$  est la taille de l'échantillon,  $T=36$  les timesteps et  $C=10$  les bandes spectrales.

### 2.4.1. Normalisation

Une normalisation min-max est appliquée bande par bande, calculée exclusivement sur le jeu d'entraînement pour éviter toute fuite d'information. Les valeurs normalisées sont bornées dans  $[0, 1]$ .

### 2.4.2. Split train/val/test

Conformément au papier, par classe, 300 points sont réservés pour l'entraînement et la validation (240 pour l'entraînement, 60 pour la validation), le reste des données étant alloué au jeu de test.

| Région     | Train | Val | Test   | Total   |
|------------|-------|-----|--------|---------|
| Arkansas   | 1 200 | 300 | ~8 500 | ~10 000 |
| California | 1 440 | 360 | ~8 220 | ~10 020 |

### 3. Partie 1 : MCNet

#### 3.1 Architecture MCTNet

Le modèle prend des entrées de dimension [B,36,10]. Il fait passer les entrées à travers trois blocs **CTFusion**. Entre chaque bloc, il insère une couche de **MaxPooling**. Enfin, il aboutit à une tête de classification finale. Chaque composant a un rôle précis dans la hiérarchie du réseau :

- **ECA (Efficient Channel Attention)** : un mécanisme d'attention léger basé sur une convolution 1D locale. ECA permet au modèle d'apprendre l'importance de chaque bande spectrale de façon dynamique, sans ajout de paramètres.
- **ALPE (Attention-based Learnable Positional Encoding)** : encodage positionnel adaptatif conçu pour combler les lacunes temporelles dans les données. Il transmet l'information des positions voisines via une convolution 1D, puis utilise ECA pour pondérer et ajuster l'importance relative de chaque position temporelle.
- **TransformerSubmodule** : une couche d'auto-attention à plusieurs têtes (dmodel=30, nhead=5) qui capture les dépendances contextuelles à long terme dans les séries temporelles.
- **CNNSubmodule** : deux couches de convolution 1D successives avec connexion résiduelle, extrayant des caractéristiques locales à différentes échelles. Cette structure permet de capturer des motifs temporels fins tout en préservant le gradient lors de la rétropropagation.
- **CTFusion** : bloc hybride qui fusionne les représentations issues du CNN et du Transformer par concaténation suivie d'une projection linéaire, combinant ainsi les patrons locaux détectés par le CNN et les dépendances à long terme capturées par le Transformer.

#### 3.2 Implémentation et entraînement

Les hyperparamètres suivent fidèlement ceux rapportés dans le papier original (Table 3) : optimiseur **Adam** avec un taux d'apprentissage  $lr=0,001$ , une taille de batch de 32, et un entraînement sur 200 epochs avec un mécanisme d'**early stopping** (patience de 40 epochs). La fonction de perte utilisée est la **CrossEntropyLoss** standard.

#### 3.3 Résultats

##### 3.3.1 Résultats Arkansas

Le tableau suivant présente les métriques obtenues sur le jeu de test Arkansas :

|                 | OA    | Kappa | F1    |
|-----------------|-------|-------|-------|
| Arkansas        | 0.936 | 0.905 | 0.884 |
| Résultat papier | 0.968 | 0.951 | 0.933 |




Figure 1 — Métriques par classe—Arkansas




Figure 2—  
Matrice de  
confusion—  
Arkansas




Figure 3 — Courbe d'entraînement— Arkansas

### 3.3.2 Résultats California

Le tableau suivant présente les métriques obtenues sur le jeu de test California :

|                 | OA    | Kappa | F1    |
|-----------------|-------|-------|-------|
| California      | 0.845 | 0.797 | 0.814 |
| Résultat papier | 0.852 | 0.806 | 0.829 |




Figure 4 — Métriques par classe—California




Figure 5 — Matrice de confusion—California

MCTNet — Entraînement California




Figure 6 — Courbe d'entraînement— California

### 3.4 Analyse des Résultats

#### Arkansas

Le modèle atteint une **OA de 0,936**, des performances proches mais légèrement inférieures aux résultats du papier (**OA = 0,968**), un écart qui s'explique par les variations d'initialisation, les contraintes matérielles limitant la capacité d'entraînement, et surtout le fait que les zones géographiques exactes utilisées dans le papier ne sont pas précisées, rendant une reproduction stricte impossible. L'analyse par classe confirme d'excellentes performances sur maïs, coton, riz et soja, classes spectralement bien séparables, tandis que la classe Others reste difficile à discriminer (**OA  $\approx$  0,434**) en raison de son hétérogénéité. Les courbes d'entraînement montrent une convergence stable régulière dès les premières epochs, sans signe de overfitting, et la matrice de confusion confirme une très bonne diagonale, avec peu de confusions inter-classes et aucun signe de underfitting.

#### California

Avec une **OA de 0,845**, les performances restent très proches du papier (**OA = 0,852**). Cette dégradation est due à la diversité des cultures (Grapes, Almonds, Peaches, etc.) et au déséquilibre de classes visible dans la distribution, ainsi que les écarts résiduels, car c'est impossible de reproduire exactement les mêmes zones d'échantillonnage (non précises dans le papier), et enfin les contraintes matérielles qui ont limité la capacité d'entraînement. Les courbes d'entraînement révèlent une instabilité plus marquée, avec des oscillations de la val\_loss autour des epochs 25–40, le meilleur modèle étant sauvegardé à l'epoch 10 via l'early stopping. La matrice de confusion indique que Rice et Alfalfa sont les classes les mieux discriminées, avec très peu de confusion inter-classes. À l'inverse, Almonds reste la classe la plus problématique, avec des confusions fréquentes vers Grapes et Others, ce qui s'explique par la similarité de leurs profils spectraux, aggravée par leur sous-représentation dans le dataset.




Figure 7— Classe de distribution— Arkansas




Figure 8 — Classe de distribution— California



## 4. Partie 2 : Intégration des covariables environnementales

La Partie 2 vise à évaluer si l'ajout de variables environnementales statiques (**climat, sol, topographie**) permet d'améliorer la précision de classification des cultures par rapport au modèle MCTNet de base (aucun changement sur le modèle d'entraînement).

### 4.1 Choix des covariables

#### 4.1.1 Covariables climatiques

Arkansas :

| Variable               | Importance (Gain) | Justification du choix                                                                                                                                                                                                                                                       | Observations sur les classes                                                                                                                                                                      |
|------------------------|-------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| temp_mean /timestep    | 0.181             | Il capture la dynamique thermique saisonnière dans le climat subtropical humide (étés chauds). Elle différencie cultures estivales (riz, coton, soja nécessitant >20°C prolongé) des hivernales via GDD, renforçant la séparabilité inter-classes.                           | Différences subtiles mais significatives : Mais légèrement plus chaud (médiane ≈17.1°C), coton plus froid (≈16.9°C)                                                                               |
| precip_total /timestep | 0.180             | Il quantifie l'apport en eau atmosphérique réellement reçu par la culture. Donc, permet de distinguer les cultures pluviales (soja, maïs) qui suivent les épisodes pluvieux des cultures irriguées ou inondées (riz) dont le régime hydrique est géré artificiellement.      | Le coton et le riz ont les médianes les plus basses (≈35-38mm) ; le coton est souvent cultivé en sols plus secs ; le riz est irrigué donc découplé de la pluie naturelle ; le soja plus variable. |
| solar_mean /timestep   | 0.195             | En Arkansas, la variabilité de la nébulosité (couverture des nuages) saisonnière crée des différences entre cultures, et solar_mean, mesure l'énergie photosynthétique disponible pou corriger les lacunes des séries satellitaires et réduire les confusions inter-classes. | Les distributions inter-classes sont relativement proches (~193–204 W/m²)                                                                                                                         |

California :

| Variable            | Importance (gain) | Justification du choix                                                                                                                                                                                                                                                      | Observation sur les classes                                                                                                                                                                                                                 |
|---------------------|-------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| temp_mean /timestep | 0.165             | Elle distingue la phénologie des cultures permanentes (noyer, amandier, pistachier) via l'accumulation de froid hivernal (chilling hours) en zones côtières fraîches de la Californie et de chaleur printanière (GDD) des zones intérieures chaudes.                        | Le pistachier affiche la médiane la plus élevée (~18.5°C), confirmant son implantation dans les zones les plus chaudes. Alfalfa présente une distribution plus large (10–20°C), reflétant présence dans des contextes géographiques variés. |
| VDP_mean /timestep  | 0.179             | En climat méditerranéen, le VPD est la principale mesure de la demande évaporative atmosphérique. C'est un discriminant fort entre cultures tolérant la sécheresse (VPD faible en zones intérieures) et cultures exigeant une irrigation soutenue (en été, VPD très élevé). | Pistaches et amandes dans les zones à forte demande évaporative (VPD plus élevé ≈1.75 kPa) ; riz et vignes dans des environnements plus humides/frais (VPD le plus bas pour le riz ≈1.48 kPa)                                               |

| Variable                    | Importance (gain) | Justification du choix                                                                                          | Observation sur les classes                                                                                                                                                                         |
|-----------------------------|-------------------|-----------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>solar_mean /timestep</b> | 0.226             | Il distingue les cultures par régimes solaires : entre la côte brumeuse, le fort rayonnement en Central Valley. | Les vignes se distinguent par les valeurs les plus élevées (~232 W/m <sup>2</sup> ), cohérent avec les zones côtières ensoleillées, et le riz avec une médiane basse, souvent sous régimes nuageux. |

**Remarque importante :** Les deux États n'utilisent pas les mêmes variables climatiques : Arkansas privilégie *précip\_totale* (pertinent pour son climat humide pluvieux), tandis que la Californie utilise le *VPD* (essentiel dans son climat méditerranéen sec et irrigué).

#### 4.1.2 Covariables pédologiques (Soil)

| Variable            | Importance (gain) | Justification du choix                                                                                                                                                                                                                   | Observation sur les classes                                                                                                                                                                                                                                                           |
|---------------------|-------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>soil_ph</b>      | 0.109             | <i>soil_ph</i> est un prédicteur statique fort de la distribution des cultures, car le modèle apprend les associations pH-culture (acide → riz ; neutre → soja/coton) invisibles dans les signaux spectraux seuls.                       | Les distributions sont proches (~5.8–6.1) pour toutes les classes, avec une faible variance inter-classes.                                                                                                                                                                            |
|                     | 0.100             | En Californie, est un marqueur fort face à l'hétérogénéité des cultures : sols alcalins en Central Valley (irrigation prolongée) vs. acides en zones viticoles côtières.                                                                 | La vigne affiche un pH légèrement inférieur (~7.3–7.5) comparé aux autres cultures (~7.5), se retrouve dans des zones viticoles côtières.                                                                                                                                             |
| <b>soil_oc</b>      | 0.050             | <i>soil_oc</i> indique la fertilité des sols alluviaux riches du Delta (riz, soja, coton intensifs). Il contextualise les forts signaux satellites de productivité et réduit les faux positifs sur sols pauvres.                         | Toutes les classes présentent des valeurs très basses. Sols alluviaux rizicoles ont OC plus élevé (médiane ~0.30 g/kg).                                                                                                                                                               |
|                     | 0.055             | Il distingue sols organiques enrichis des vergers irrigués (Central Valley) des sols pauvres semi-arides. Il sépare cultures pérennes établies des annuelles sur terres appauvries.                                                      | Les valeurs sont globalement très faibles (<0.5 g/kg). Le riz présente une médiane légèrement supérieure (~0.5 g/kg).                                                                                                                                                                 |
| <b>soil_texture</b> | 0.067             | <i>soil_texture</i> identifie les sols argilo-limoneux lourds du Delta, indispensables pour retenir l'eau en riziculture inondée. Elle est un prédicteur spatial clé distinguant le riz des cultures sur sols sableux à drainage rapide. | Maïs/Coton/Riz autour de 7-8 ce qui indique qu'ils préfèrent les sols à argiles lourdes (drainage faible). Le Soja très variable (4-8), occupe une plus grande diversité de textures.                                                                                                 |
|                     | 0.063             | <i>soil_texture</i> révèle la forte diversité agricole californienne : sols sableux côtiers (Salinas Valley) vs sols argilo-limoneux (Central Valley).                                                                                   | Le alfalfa, se distingue avec une médiane à 7 et une boîte quasi plate (variance presque nulle), indiquant qu'elle cultivé sur un type de sol spécifique. Le riz et les vignes ont des textures légères (médiane ~4), contrastant avec l'amande et "Other" à textures plus variables. |

### 4.1.3 Covariables topographiques

| Variable         | Importance (gain) | Justification du choix                                                                                                                                                                                                                                                         | Observations sur les classes                                                                                                                                                                                                                  |
|------------------|-------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Elevation</b> | 0.156             | L'altitude structure les zones agro climatiques verticales via son effet sur la température et la durée de la saison de végétation. En Arkansas, elle sépare les deux grands contextes agricoles ; le Delta alluvial plat (<100) et les uplands (~300–800m) à usage différent. | Le maïs présente la distribution altitudinale la plus large et variable (40–90m), indiquant qu'il s'étend au-delà du Delta. Les autres cultures (riz, coton, soja) sont concentrées à basse altitude (~50–65m).                               |
|                  | 0.175             | La Californie présente une variabilité altitudinale extrême (0m à >1400m). La Central Valley à basse altitude pour les grandes cultures irriguées, les piémonts (200–600m) pour les vergers et vignobles.                                                                      | La plupart des cultures sont concentrées en dessous de 200m (riz, vignes, amande, pistache). En revanche, la classe "Other" présente une distribution extrêmement étendue (jusqu'à 1400m+), ce qui reflète l'inclusion de zones non agricoles |
| <b>Landforms</b> | 0.067             | Décrivent la morphologie du terrain (plaines, terrasses, alluviales) et conditionnent le drainage naturel et la mécanisation. Arkansas est dominé par des plaines alluviales.                                                                                                  | Les distributions sont similaires entre classes (~30–35), avec une variabilité légèrement plus forte pour le maïs et "Other".                                                                                                                 |
|                  | 0.039             | Les formes du relief distingue fonds de vallée (Central Valley, grandes cultures), zones alluviaux/terrasses (vergers, vignes), et versants (viticulture Napa). Faiblement discriminante seule, elle complète l'élévation pour la structure fine du relief.                    | C'est la variable la moins discriminante : les distributions sont très similaires entre toutes les classes (24–35), avec des boîtes larges.                                                                                                   |

Graphes permettant l'analyse de l'importance des covariables et leur variation par classe :




Figure 9 — Importance des covariable — Arkansas




Figure 10 — Boxplots des covariables par classe — Arkansas




Figure 11— Importance des covariable – California




Figure 12 — Boxplots des covariables par classe – California

## 4.2 Résultats Ablation

### 4.2.1 Résultats Arkansas

Le tableau suivant présente les métriques obtenues par l'étude d'ablation sur le jeu de test Arkansas :

| Configuration   | OA    | Kappa | F1    |
|-----------------|-------|-------|-------|
| S2 only         | 0.936 | 0.905 | 0.881 |
| S2 + Climat     | 0.921 | 0.883 | 0.886 |
| S2 + Sol        | 0.898 | 0.852 | 0.835 |
| S2 + Topography | 0.923 | 0.886 | 0.870 |
| S2 + Tout       | 0.937 | 0.906 | 0.882 |




Figure 13— Résultats de l'étude d'ablation systématique — Arkansas




Figure 14— Courbes d'apprentissage des 5 configurations — Arkansas




Figure 15— Gain/perte des configurations vs baseline (S2 only) Arkansas

## 4.2.1 Résultats California

Le tableau suivant présente les métriques obtenues par l'étude d'ablation sur le jeu de test California :

| Configuration   | OA    | Kappa | F1    |
|-----------------|-------|-------|-------|
| S2 only         | 0.842 | 0.793 | 0.819 |
| S2 + Climat     | 0.834 | 0.782 | 0.795 |
| S2 + Sol        | 0.827 | 0.776 | 0.811 |
| S2 + Topography | 0.831 | 0.778 | 0.806 |
| S2 + Tout       | 0.817 | 0.766 | 0.796 |




Figure 16 — Résultats de l'étude d'ablation systématique — California




Figure 17 — Courbes d'apprentissage des 5 configurations — California




Figure 18—Gain/perte des configurations vs baseline (S2 only) —California

### 4.2.3 Discussion et analyse comparative

#### Arkansas :

Le modèle baseline S2-only atteint déjà des performances très élevées (OA = 0.936, Kappa = 0.905, F1 = 0.881), ce qui rend difficile toute amélioration significative par l'ajout de covariables; ainsi, l'ajout de chaque groupe de covariables entraîne systématiquement une dégradation des performances par rapport au baseline. Le groupe Sol est de loin le plus pénalisant, avec des chutes de -3.82 points d'OA, -5.32 points de Kappa et -4.60 points de F1. Ce comportement suggère que les variables pédologiques (pH, texture, OC Sol), bien qu'informatives en théorie, introduisent un conflit avec les signaux spectraux temporels. La configuration Climat (OA = 1.50, Kappa = 2.16, F1 = -1.52) et Topo (OA = 1.29, Kappa = 1.85, F1 = -1.19) causent des dégradations plus modérées, mais restent négatifs. La combinaison de toutes les covariables (S2 + Tout) est la seule configuration qui dépasse légèrement le baseline : +0.10 point d'OA et +0.15 point de Kappa, avec un F1 presque identique. Le modèle bénéficie de la complémentarité entre les groupes, qui se compensent mutuellement.

Les courbes de validation Loss révèlent une instabilité notable pour S2 + Sol (pic aux epochs 8–10), confirmant la difficulté d'intégration de ces covariables. Les configurations S2 + Climat et S2 + Topo présentent des courbes plus stables, proches du baseline. S2 + Tout montre des oscillations persistantes dues aux bruits importants dans les données.

Tout de même, toutes les configurations restent significativement en dessous des performances reportées dans le papier de référence (OA = 0.968, Kappa = 0.951, F1 = 0.933); cela peut être attribué aux mauvais choix de variables, à l'évaluation sur des zones géographiques moins favorables, aux variables d'initialisation qui nécessiteraient des ajustements et aux contraintes matérielles limitant la capacité d'entraînement.

#### California :

Les résultats californiens présentent un profil plus problématique : contrairement à l'Arkansas, aucune configuration avec covariables ne dépasse le baseline S2-only (OA = 0.842, Kappa = 0.793, F1 = 0.819), et l'ajout de covariables dégrade les performances de façon systématique et croissante. La configuration Climat entraîne la perte la plus sévère (OA = -0.81, Kappa = -1.07, F1 = -2.42), OA modérément affecté mais F1 fortement dégradé. Cela révèle que les covariables climatiques perturbent en priorité la classification des classes minoritaires pour lesquelles le F1 est plus sensible, sans autant dégrader la précision globale. Le groupe Sol présente un profil opposé : impact OA plus fort mais F1 mieux préservé (OA = -1.44, Kappa = -1.71, F1 = -0.76), indiquant que les variables pédologiques affectent davantage les classes majoritaires. La Topographie est intermédiaire (OA = -1.08, Kappa = -1.50, F1 = -1.27). Résultatation de toutes les covariables (S2 + Tout) produit la dégradation la plus sévère (OA = -2.45, Kappa = -2.50, F1 = -2.33), un résultat totalement cohérent au vu des résultats des configurations prises séparément. Les courbes

montrent une convergence rapide durant les premières epochs (~epoch 10–15), suivie par des oscillations persistantes de la validation loss et de la validation accuracy. Cela suggère que le modèle atteint rapidement une performance proche de l'optimum. Ces résultats s'expliquent par la grande diversité agricole californienne (6 classes très hétérogènes spectralement et géographiquement), qui peut rendre l'intégration de covariables statiques plus difficile à apprendre en interaction avec les séries temporelles, ou par un réglage sous-optimal des paramètres du système.

## 5. Partie 3 : Conception et amélioration de modèles

### 5.1 objectifs

Après avoir reproduit fidèlement le pipeline MCTNet dans la Partie 1 et intégré des covariables environnementales dans la Partie 2, la Partie 3 a pour objectif de proposer une amélioration originale du modèle de classification de cultures.

Pour cette partie, on s’est inspirés par les résultats acquis et sur un autre article publié<sup>2</sup>.

### 5.2 Enrichissement des données

#### 5.2.1 Motivation

Dans la Partie 1, le modèle recevait en entrée uniquement les 10 bandes spectrales Sentinel-2, sur 36 timesteps. Or, les bandes spectrales brutes encodent l'information de manière redondante pour certaines tâches agricoles. Dans la Partie 3, cinq indices de végétation sont calculés pour chaque point et chaque timestep, et concaténés aux bandes spectrales originales. Le vecteur de features passe ainsi de 10 à 15 dimensions.

#### 5.2.2 Les indices de végétation

Les **indices de végétation**, calculés comme des combinaisons rationnelles des bandes Sentinel-2 disponibles dans le dataset, permettent d'extraire une information plus directement liée à l'état physiologique de la végétation, réduisant ainsi la charge d'apprentissage du modèle. Le tableau suivant récapitule les cinq indices ajoutés :

| Indice | Formule                                                                                                  | Description                                                                       |
|--------|----------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------|
| NDVI   | $(\text{NIR} - \text{Red}) / (\text{NIR} + \text{Red})$                                                  | Indice de végétation normalisé — mesure la densité et l'activité chlorophyllienne |
| EVI    | $2.5 \times (\text{NIR} - \text{Red}) / (\text{NIR} + 6 \times \text{Red} - 7.5 \times \text{Blue} + 1)$ | Indice de végétation amélioré — moins saturé dans les zones à forte biomasse      |
| NDWI   | $(\text{NIR} - \text{SWIR}) / (\text{NIR} + \text{SWIR})$                                                | Indice d'eau normalisé — sensible à la teneur en eau de la végétation             |
| GNDVI  | $(\text{NIR} - \text{Green}) / (\text{NIR} + \text{Green})$                                              | Variante verte du NDVI — plus sensible à la teneur en chlorophylle                |
| NDRE   | $(\text{NIR} - \text{RedEdge}) / (\text{NIR} + \text{RedEdge})$                                          | Indice de red-edge normalisé — indicateur de stress et maturité végétale          |

Les indices de végétation sont normalisés avec la même stratégie **min-max** que les bandes spectrales, calculée exclusivement sur le jeu d'entraînement.

#### Analyse Graphes des indices de végétation calculés :

<sup>2</sup> Deep Learning Applications for Crop Mapping Using Multi-Temporal Sentinel-2 Data and Red-Edge Vegetation Indices: Integrating Convolutional and Recurrent Neural Networks






Figure 19 — Profils temporels moyens : indices de végétation (NDVI, EVI, NDWI, GNDVI, NDRE) — Arkansas

Les profils temporels des cinq indices (NDVI, EVI, NDWI, GNDVI, NDRE) révèlent des comportements phénologiques bien distincts selon les cultures. Le **riz** se démarque clairement avec un pic précoce et fort dès les premiers timesteps, particulièrement visible sur le NDWI, ce qui reflète directement la présence d'eau lors de l'inondation des parcelles en début de cycle cultural. Le **maïs** atteint quant à lui les valeurs les plus élevées en milieu de saison sur le NDVI et le GNDVI, indiquant une biomasse foliaire dense et une activité photosynthétique maximale autour des timesteps 17-21. Le **coton** atteint un pic tardif vers les timesteps 21-25 et maintient des valeurs élevées en fin de saison. Le **soja** présente un profil intermédiaire, relativement proche du maïs mais avec une végétation moins dense. Enfin, la classe **Others** montre une forte variabilité, ce qui reflète son caractère hétérogène.




Figure 20 — Profils temporels moyens : indices de végétation (NDVI, EVI, NDWI, GNDVI, NDRE) — California

Les profils des six cultures californiennes (vignes, riz, luzerne, amandes, pistaches, autres) révèlent une dynamique nettement plus complexe qu'en Arkansas, avec des classes plus difficiles à séparer.

Le **riz** reste la culture la plus reconnaissable, son profil est caractérisé par un creux en début de saison suivi d'un pic tardif très prononcé (timesteps 17–25) sur le NDVI et le NDWI, avec ensuite une chute brutale en fin d'année. Cette forme en cloche asymétrique le distingue clairement des autres cultures. L'**alfalfa** (luzerne) se démarque par des valeurs élevées et relativement stables tout au long de la saison, ce qui est cohérent avec ses multiples cycles biologiques annuels. Les cultures arboricoles (**amandiers** et **pistachiers**) présentent des profils modérés et peu dynamiques, sans variation saisonnière marquée, ce qui les rend difficiles à différencier entre elles. Les **vignes** ont des valeurs intermédiaires et une forte variabilité intra-classe.

En résumé, la dimension temporelle est essentielle : les classes sont souvent confondues à un instant donné mais deviennent séparables sur l'ensemble du profil saisonnier, ce qui justifie l'utilisation de modèles capables d'exploiter cette dynamique temporelle pour la classification.

### 5.2.3 Dimensions finales des datasets

| Région     | Train           | Validation    | Test            |
|------------|-----------------|---------------|-----------------|
| Arkansas   | (1200, 36, 15)  | (300, 36, 15) | (8500, 36, 15)  |
| California | (1 440, 36, 15) | (360, 36, 15) | (8 220, 36, 15) |




Figure 21 — Distribution des classes (nombres d'échantillons et train / val / test) — Arkansas




Figure 22 — Distribution des classes (nombres d'échantillons et train / val / test) — California

## 5.3 Architecture du modèle — Part3Net

Le modèle proposé, désigné **Part3Net**, constitue une évolution directe de MCTNet. L'objectif a été de rester aussi proche que possible de l'architecture de référence, tout en introduisant deux innovations : un module de **Feature Attention** en entrée et un embedding d'entrée adapté aux 15 features.

### 5.3.1 Module FeatureAttention

Le module FeatureAttention est un réseau MLP léger appliqué sur l'axe des features. Pour chaque point de la série temporelle, il calcule un vecteur de pondération de dimension 15, indiquant l'importance relative de chaque feature. Son architecture est la suivante :

- Couche Linear(15  $\rightarrow$  8) + ReLU
- Couche Linear(8  $\rightarrow$  15) + Sigmoid

Le vecteur de sortie est utilisé pour pondérer les features d'entrée par multiplication élément par élément. Ce mécanisme d'attention léger permet au réseau de concentrer son apprentissage sur les variables les plus discriminantes.

### 5.3.2 Flux global du modèle

Le flux de données au sein du modèle suit les étapes suivantes :

| Composant        | Dimensions                          | Description                                                                             |
|------------------|-------------------------------------|-----------------------------------------------------------------------------------------|
| Entrée           | [B, 36, 15]                         | Tenseur de forme (Batch, 36 Timesteps, 10 Features) avec masque des données manquantes. |
| FeatureAttention | 15 $\rightarrow$ 8 $\rightarrow$ 15 | Pondération automatique des variables les plus pertinentes.                             |

|                          |                             |                                                                                                                         |
|--------------------------|-----------------------------|-------------------------------------------------------------------------------------------------------------------------|
| <b>Input Embedding</b>   | 15 → 36 (d_model)           | Projection linéaire pour aligner la dimension des features avec d_model du backbone                                     |
| <b>3 blocs CTFusion</b>  | [B, 36, 36]                 | CNN + Transformer avec ALPE + ECA                                                                                       |
| <b>Global MaxPooling</b> | 9 → 1 → 36-dim              | Agrégation des informations temporelle                                                                                  |
| <b>Classifieur</b>       | Dropout(0.12)<br>Linear     | +<br>prédiction finale des classes via couche linéaire :<br>Linear(36 → N_classes) : 5 pour Arkansas, 6 pour California |
| <b>Paramètres total</b>  | 84 872 (ARK) / 84 878 (CAL) | Légèrement supérieur à MCTNet grâce au FeatureAttention et Input Embedding                                              |

Les blocs CTFusion sont identiques à ceux de MCTNet. Chaque bloc effectue une fusion des sorties d'un **CNNSubmodule** et d'un **TransformerSubmodule**.

### 5.3.3 Hyperparamètres

Les hyperparamètres d'entraînement ont été conservés identiques à ceux de la Partie 1 afin d'assurer une comparaison équitable :

| Hyperparamètre                   | Valeur           |
|----------------------------------|------------------|
| <b>Optimiseur</b>                | Adam             |
| <b>Taux d'apprentissage</b>      | 0.001            |
| <b>Taille de batch</b>           | 32               |
| <b>Epochs max</b>                | 180              |
| <b>Patience (early stopping)</b> | 40               |
| <b>Dropout</b>                   | 0.12             |
| <b>Fonction de perte</b>         | CrossEntropyLoss |
| <b>Seed de référence</b>         | 42               |

## 5.4 Résultats

### 5.4.1 Résultats Arkansas

Le tableau suivant compare les métriques obtenues par la Partie 1 et la Partie 3 sur le jeu de test Arkansas :

| Modèle                       | OA    | Kappa | F1 macro |
|------------------------------|-------|-------|----------|
| Baseline — Partie 1 (MCTNet) | 0.936 | 0.905 | 0.884    |
| Modèle Part 3                | 0.953 | 0.929 | 0.905    |




Figure 23 — Comparaison des métriques globales Part 1 vs Part 3 — Arkansas




Figure 24 — Métrique par classe — Arkansas




Figure 25 — Courbes d'entraînement Part 3 (perte / Précision / Macro-F1) — Arkansas




Figure 26 — Matrice de confusion normalisée

Part 3 — Arkansas

## 5.4.2 Résultats California

Le tableau suivant compare les métriques obtenues par la Partie 1 et la Partie 3 sur le jeu de test California :

| Modèle                       | OA    | Kappa | F1 macro |
|------------------------------|-------|-------|----------|
| Baseline — Partie 1 (MCTNet) | 0.845 | 0.797 | 0.814    |
| Modèle Part 3                | 0.863 | 0.821 | 0.842    |




Figure 27 — Comparaison des métriques globales Part 1 vs Part 3 — California




Figure 28 — Métrique par classe — California




Figure 29 — Courbes d'entraînement Part 3 (perte / Précision / Macro-F1) — California




Figure 30 — Matrice de confusion normalisée

Part 3 — California

### 5.4.3 Discussions et analyse comparatives

#### Arkansas :

Le modèle amélioré de la Partie 3 dépasse clairement le baseline MCTNet de la Partie 1 sur l'ensemble des métriques : OA passe de 0.936 à **0.953** (+1.70 pts), Kappa de 0.905 à **0.929** (+2.40 pts), et F1 macro de 0.884 à **0.905** (+2.10 pts). Ces gains, bien que modérés en valeur absolue, sont significatifs compte tenu du niveau de performance déjà très élevé des résultats de partie 1, où chaque point supplémentaire est difficile à obtenir.

L'analyse par classe révèle des performances quasi-parfaites sur le **maïs** (F1 = 0.981), le **riz** (F1 = 0.990) et le **coton** (F1 = 0.928), confirmant que ces cultures spectralement distinctes bénéficient pleinement des améliorations apportées par le nouveau modèle. Le **soja** progresse également de manière notable (F1 = 0.958), traduisant une meilleure capacité à discriminer cette culture des classes voisines. La classe **autres**

reste la plus problématique ( $F1 = 0.666$ ), avec une précision faible ( $P = 0.523$ ) mais un rappel élevé ( $R = 0.916$ ) : le modèle tend à sur-identifier cette classe hétérogène (le modèle prédit "Others" trop souvent, y compris pour des échantillons qui appartiennent à d'autres classes), ce qui suggère que son amélioration nécessiterait une meilleure représentation des sous-classes qui la composent.

**La matrice de confusion** confirme une diagonale très propre, avec les principales confusions résiduelles concentrées entre "Soybean" et "Others" (0.053), reflet de leur proximité spectrale en fin de saison.

**Les courbes d'entraînement** montrent une convergence rapide dès les premiers epochs, avec une validation loss qui stabilise autour de 0.25–0.30 après quelques oscillations initiales. Le gap entre les courbes train et validation, bien que visible, reste contenu et ne montre pas de surapprentissage sévère. La précision et le Macro-F1 de validation se stabilisent respectivement autour de 95–97%, de manière cohérente avec les métriques de test finales.

### **California :**

En Californie, le modèle de la Partie 3 réalise également des gains constants sur les trois métriques : OA de 0.845 à **0.863** (+1.80 pts), Kappa de 0.797 à **0.821** (+2.40 pts), F1 macro de 0.814 à **0.842** (+2.80 pts).

Ces améliorations sont particulièrement notables sur le F1, ce qui indique que le nouveau modèle gère mieux les classes minoritaires ou difficiles, là où le baseline MCTNet montrait davantage de faiblesse.

L'analyse par classe confirme des performances excellentes sur **riz** ( $F1 = 0.988$ ) et l'**alfalfa** (luzerne) ( $F1 = 0.944$ ). Le **pistachier** progresse de façon marquée ( $F1 = 0.851$ ,  $R = 0.962$ ), ce qui suggère que le modèle capture mieux la dynamique phénologique tardive propre aux arboricoles. Les **vignes** restent intermédiaire ( $F1 = 0.836$ ), avec des confusions persistantes vers les **amandes** ( $F1 = 0.076$ ) et **Others** ( $F1 = 0.060$ ), reflétant la proximité spectrale de ces cultures de vergers. L'**amande** demeure la classe la plus difficile ( $F1 = 0.576$ ,  $P = 0.444$ ) : malgré un rappel correct ( $R = 0.821$ ), la précision très basse indique que le modèle confond fréquemment d'autres classes avec les amandiers, ce qui s'explique par leur sous-représentation dans le dataset et la similarité de leur signature spectrale avec les **vignes** et la classe **Others**.

**La matrice de confusion** illustre ce constat, avec des fuites importantes d'amandes vers vignes (0.071) et Others (0.098), et réciproquement.

**Les courbes d'entraînement** californiennes révèlent une dynamique plus turbulente que pour l'Arkansas : la validation loss présente des oscillations prononcées entre les epochs 5 et 25, avant de se stabiliser autour de 0.45–0.50 ; cette instabilité est cohérente avec la grande hétérogénéité du dataset (6 classes spectralement proches). Le gap train-val est plus marqué qu'en Arkansas, avec un train qui converge vers 100% tandis que la validation plafonne autour de 88–90%, indiquant un léger surapprentissage résiduel difficile à éviter à cause de la complexité du problème.

### **5.4.4 Conclusion**

Dans les deux régions, le modèle Partie 3 surpasse systématiquement le baseline MCTNet et se rapproche davantage des performances reportées dans le papier de référence (Arkansas : OA = 0.968 ; California : OA = 0.852). Les écarts résiduels restent attribuables aux mêmes facteurs : zones géographiques d'échantillonnage qui ne sont pas identiques, contraintes matérielles limitant la durée et la profondeur de l'entraînement, et hétérogénéité intrinsèque de la classe Others dans les deux régions.

## 6. Conclusion générale

Ce projet s'est articulé autour de trois axes progressifs visant à explorer, étendre et améliorer la classification des cultures agricoles à partir de séries temporelles Sentinel-2 par apprentissage profond, appliqués à deux régions contrastées : l'Arkansas et la Californie.

La **Partie 1** a posé une base solide en reproduisant exactement l'architecture MCTNet, validant la pertinence de l'approche hybride CNN-Transformer pour modéliser les dépendances temporelles et spectrales des séries satellitaires, avec des performances très proches de celles publiées dans le papier de référence.

La **Partie 2** a montré que l'enrichissement par covariables environnementales statiques sur le même backbone MCTNet ne conduit pas à une amélioration généralisée. Ce constat, bien que décevant au premier abord, constitue en lui-même une contribution analytique utile, en délimitant clairement les conditions où ce type d'intégration est bénéfique ou non.

La **Partie 3** a confirmé qu'une amélioration plus robuste est atteignable en travaillant sur l'architecture elle-même, avec des gains constants sur les deux régions et sur l'ensemble des métriques. Les classes hétérogènes et sous-représentées demeurent néanmoins les principales sources d'erreur, révélant des limites associées aux données plus qu'à l'architecture.

De manière transversale, l'Arkansas et la Californie illustrent deux problématiques complémentaires : la première, favorable et bien structurée phénologiquement ; la seconde, nettement plus complexe, mettant en évidence la nécessité de modèles plus expressifs et de données d'entraînement plus représentatives. En perspective, l'utilisation des variables supplémentaires à meilleure résolution, des mécanismes de fusion plus avancés, et étendre l'étude à d'autres régions constitueraient des pistes naturelles pour poursuivre ce travail.